UTS

PEMBELAJARAN MESIN



NAMA : Karina Aulia Wulandari

NIM : 202431047

KELAS : E

DOSEN : Rizqia Cahyaningtyas, S. T., M. Kom.

NO.PC : 06

ASISTEN : 1. Muhammad Caisar Gemilang Pratama

2. Benedict Samuel Ardy

INSTITUT TEKNOLOGI PLN

TEKNIK INFORMATIKA

2026/2027

DAFTAR ISI

DAFTAR ISI **2**
BAB I **4**
PENDAHULUAN **4**
1.1 Rumusan Masalah **4**
1.2 Tujuan Masalah **4**
1.3 Manfaat Masalah **4**
BAB II **5**
LANDASAN TEORI **5**
2.1 Klasifikasi dalam Data Mining dan Konteks Data Pemasaran Bank **5**
2.2 Analisis Data Eksploratif (EDA) **5**
2.3 Pra-pemrosesan Data: Encoding dan Penskalaan Fitur **5**
2.4 Naive Bayes **6**
2.5 K-Nearest Neighbors (KNN) **6**
2.6 Pembagian Data dan Evaluasi Model **6**
BAB III **7**
HASIL **7**
3.1 Persiapan Library dan Pemuatan Data **7**
3.2 Analisis Data Eksploratif **7**
3.2.1 Ukuran data, nilai hilang, dan duplikasi 8
3.2.2 Statistik deskriptif 8
3.2.3 Distribusi target (y) 8
3.2.4 Distribusi fitur numerik 9
3.2.5 Fitur kategorikal terhadap target 9
3.2.6 Korelasi fitur numerik 9
3.3 Naive Bayes **10**
3.3.1 Preprocessing (Label Encoding) 10
3.3.2 Pembagian data dan pelatihan 10
3.3.3 Evaluasi 10
3.3.4 Prediksi nasabah baru 11
3.4 K-Nearest Neighbors **11**

3.4.1 Load data dan preprocessing 11
3.4.2 Pembagian data 12
3.4.3 KNN tanpa scaling (K = 7) 12
3.4.4 KNN dengan scaling (StandardScaler) 12
3.4.5 Pemilihan nilai K terbaik 12
3.4.6 Evaluasi KNN terbaik 13
3.4.7 Prediksi data baru (KNN) 13
3.5 Perbandingan Naive Bayes dan KNN 14
BAB IV 15
PENUTUP 15
DAFTAR PUSTAKA 16

BAB I

PENDAHULUAN

1.1 Rumusan Masalah

Praktikum ini merumuskan masalah sebagai berikut:

1. Bagaimana karakteristik data nasabah bank (ukuran data, tipe fitur, nilai hilang, duplikasi, sebaran target, sebaran fitur numerik dan kategorikal) berdasarkan analisis data eksploratif (EDA)?
2. Bagaimana tahap pra-pemrosesan yang tepat agar data kategorikal dapat dipakai oleh algoritma Naive Bayes dan K-Nearest Neighbors (KNN)?
3. Seberapa baik kinerja model Naive Bayes (GaussianNB) dalam memprediksi apakah nasabah menjawab yes atau no?
4. Model mana yang lebih baik antara Naive Bayes dan KNN, dan apakah keduanya benar-benar lebih baik daripada baseline yang selalu menebak kelas mayoritas?

1.2 Tujuan Masalah

Berdasarkan rumusan masalah di atas, tujuan dan hasil yang diperoleh dari UTS praktikum ini adalah:

1. Memahami struktur dan kualitas data nasabah bank melalui EDA, yaitu pemeriksaan ukuran data, nilai hilang, data duplikat, distribusi target, histogram dan boxplot fitur numerik, hubungan fitur kategorikal terhadap target, serta korelasi antar fitur numerik.
2. Menerapkan pra-pemrosesan data: Label Encoding untuk Naive Bayes, serta One-Hot Encoding (get_dummies dengan drop_first) dan StandardScaler untuk KNN.
3. Membangun dan mengevaluasi model Gaussian Naive Bayes dengan pembagian data latih 75% dan data uji 25%, menggunakan akurasi, confusion matrix, dan classification report.
4. Membangun model KNN tanpa dan dengan scaling, menelusuri nilai K ganjil dari 1 sampai 19, lalu memilih K terbaik dan mengevaluasinya.
5. Membandingkan akurasi Naive Bayes, KNN tanpa scaling, KNN dengan scaling, dan baseline kelas mayoritas, lalu menarik kesimpulan model yang paling layak digunakan.

1.3 Manfaat Masalah

Manfaat yang diperoleh dari UTS praktikum ini adalah:

1. Manfaat akademis: memberikan pengalaman langsung menjalankan alur kerja klasifikasi secara utuh, mulai dari EDA, pra-pemrosesan, pelatihan, evaluasi, hingga prediksi data baru, sekaligus memahami perbedaan cara kerja algoritma probabilistik (Naive Bayes) dan berbasis jarak (KNN).
2. Manfaat metodologis: menunjukkan bahwa pilihan encoding, penskalaan, dan nilai K berpengaruh pada hasil, serta bahwa akurasi harus dibandingkan dengan baseline karena data target biasanya tidak seimbang.
3. Manfaat praktis: memberi gambaran bagi pihak bank tentang bagaimana model klasifikasi dapat membantu memprioritaskan nasabah yang berpotensi menerima penawaran sehingga sumber daya pemasaran lebih efisien.
4. Manfaat bagi pengembangan selanjutnya: menjadi dasar untuk eksperimen lanjutan, misalnya penanganan data tidak seimbang, validasi silang, dan pembandingan dengan algoritma lain.

BAB II
LANDASAN TEORI

2.1 Klasifikasi dalam Data Mining dan Konteks Data Pemasaran Bank

Klasifikasi adalah teknik pembelajaran terawasi (supervised learning) yang mempelajari pola dari data berlabel untuk memprediksi kelas data baru. Dalam bidang perbankan, klasifikasi banyak dipakai untuk memprediksi respons nasabah terhadap penawaran produk, misalnya deposito berjangka, berdasarkan data historis kampanye telepon. Hayder dkk. (2023) membandingkan k-nearest neighbors, decision tree, naive Bayes, dan support vector machine pada data pemasaran bank Portugis untuk memprediksi apakah nasabah akan berlangganan deposito berjangka, dan melaporkan bahwa decision tree memberi akurasi tertinggi sekitar 91% sedangkan SVM sekitar 89%. Studi tersebut juga menekankan bahwa data pemasaran bank bersifat tidak seimbang (imbalanced), yang dapat membuat algoritma seperti KNN dan Naive Bayes berkinerja kurang baik.

Secara umum, fitur pada data nasabah terdiri dari dua jenis: fitur numerik (misalnya usia, saldo, durasi kontak) dan fitur kategorikal (misalnya pekerjaan, pendidikan, bulan kontak). Perbedaan jenis fitur ini menentukan cara pra-pemrosesan yang dibutuhkan sebelum model dilatih.

2.2 Analisis Data Eksploratif (EDA)

EDA adalah tahap awal untuk memahami data sebelum pemodelan. Tahap ini mencakup pemeriksaan dimensi data, tipe data, nilai hilang, data duplikat, dan statistik deskriptif; visualisasi distribusi (histogram, boxplot) untuk melihat sebaran dan pencilan; visualisasi hubungan fitur kategorikal dengan target; serta matriks korelasi untuk melihat keterkaitan linier antar fitur numerik. Pemeriksaan distribusi target sangat penting pada kasus klasifikasi karena proporsi kelas yang timpang akan memengaruhi cara membaca akurasi (Hayder dkk., 2023).

2.3 Pra-pemrosesan Data: Encoding dan Penskalaan Fitur

Algoritma pembelajaran mesin pada scikit-learn memerlukan masukan numerik. Label Encoding mengubah setiap kategori menjadi bilangan bulat, sedangkan One-Hot Encoding mengubah setiap kategori menjadi kolom biner terpisah. Label Encoding ringkas tetapi menyisipkan urutan semu antar kategori, sedangkan One-Hot Encoding menghindari urutan semu namun menambah jumlah fitur. Pada penggunaan drop_first, satu kolom per fitur dibuang untuk menghindari redundansi.

Algoritma berbasis jarak Euclidean sensitif terhadap rentang nilai fitur. Peshawa (2022) menjelaskan bahwa penskalaan dilakukan untuk mempercepat pelatihan dan meningkatkan efisiensi model, dan normalisasi min-max dipakai agar fitur dengan rentang besar tidak mendominasi fitur berrentang kecil dalam pengambilan keputusan KNN. Niño-Adan dkk. (2022) menganalisis pengaruh normalisasi statistik pada KNN dan K-Means dan menyimpulkan bahwa normalisasi dapat dipandang sebagai metode pembobotan fitur tanpa pengawasan; artinya normalisasi tidak otomatis menyamakan kontribusi semua fitur dan dampaknya bergantung pada masalah yang dihadapi. Standardisasi (z-score) yang digunakan

pada praktikum ini mengubah setiap fitur menjadi bernilai rata-rata 0 dan simpangan baku 1. Statistik penskalaan hanya boleh dihitung dari data latih, lalu diterapkan ke data uji, untuk mencegah kebocoran informasi.

2.4 Naive Bayes

Naive Bayes adalah keluarga pengklasifikasi probabilistik berbasis teorema Bayes yang menghitung probabilitas posterior suatu kelas berdasarkan nilai fitur:

$$P(kelas \mid x1, x2, \dots, xn) \propto P(kelas) \times P(x1 \mid kelas) \times P(x2 \mid kelas) \times \dots \times P(xn \mid kelas)$$

Kata naive merujuk pada asumsi bahwa antar fitur saling bebas secara bersyarat jika kelasnya diketahui. Wickramasinghe dan Kalutarage (2021) mengulas aplikasi, variasi, dan kelemahan Naive Bayes; algoritma ini sederhana, cepat, dan efisien, namun asumsi independensi sering tidak terpenuhi pada data nyata. Liu dkk. (2024) juga membahas upaya melonggarkan asumsi independensi bersyarat tersebut karena pelanggaran asumsi dapat menurunkan kualitas prediksi. Pada varian Gaussian Naive Bayes (GaussianNB), setiap fitur numerik pada tiap kelas diasumsikan berdistribusi normal, sehingga model hanya perlu menaksir rata-rata dan varians per fitur per kelas. Konsekuensinya, fitur kategorikal yang hanya di-label-encode akan diperlakukan seolah-olah variabel kontinu, sehingga hasilnya perlu dibaca dengan hati-hati.

2.5 K-Nearest Neighbors (KNN)

KNN adalah algoritma berbasis instans (lazy learning) yang tidak membangun model eksplisit saat pelatihan. Untuk data baru, KNN menghitung jarak (umumnya Euclidean) ke seluruh data latih, mengambil K tetangga terdekat, lalu menentukan kelas melalui suara mayoritas. Nilai K yang kecil membuat model sensitif terhadap derau dan rentan overfitting, sedangkan K yang besar membuat batas keputusan lebih halus tetapi dapat mengabaikan pola lokal; karena itu K dicari secara empiris. Karena bergantung pada jarak, KNN sangat dipengaruhi oleh penskalaan fitur (Niño-Adan dkk., 2022; Peshawa, 2022) dan, sebagaimana dicatat Hayder dkk. (2023), dapat terpengaruh oleh ketidakseimbangan kelas.

2.6 Pembagian Data dan Evaluasi Model

Data dibagi menjadi data latih untuk membangun model dan data uji untuk menilai kemampuan generalisasi. Evaluasi klasifikasi biner menggunakan confusion matrix yang memuat true positive, true negative, false positive, dan false negative. Dari sana diturunkan akurasi, precision, recall, dan F1-score. Pada data tidak seimbang, akurasi saja bisa menyesatkan karena model yang selalu menebak kelas mayoritas pun dapat tampak akurat; karena itu akurasi perlu dibandingkan dengan baseline kelas mayoritas dan dilengkapi precision, recall, serta F1 untuk kelas minoritas (Hayder dkk., 2023). Perbandingan akurasi data latih dan data uji juga digunakan untuk mendeteksi overfitting.

BAB III

HASIL

3.1 Persiapan Library dan Pemuatan Data

Program mengimpor pandas dan numpy untuk pengolahan data, serta matplotlib dan seaborn untuk visualisasi. Data dibaca dari file 04_bank_customers.csv dengan pemisah titik koma (sep=';'). Dataset memiliki 16 fitur dan 1 target y, dengan fitur: age, job, marital, education, default, balance, housing, loan, contact, day, month, duration, campaign, pdays, previous, dan poutcome.

```
In [9]:
# KarinaAuliaWulandari - 202431047
data.head()
```

Out[9]:

	age	job	marital	education	default	balance	housing	loan	contact	day	month	du
0	58	management	married	tertiary	no	2143	yes	no	unknown	5	may	
1	44	technician	single	secondary	no	29	yes	no	unknown	5	may	
2	33	entrepreneur	married	secondary	no	2	yes	yes	unknown	5	may	
3	47	blue-collar	married	unknown	no	1506	yes	no	unknown	5	may	
4	33	unknown	single	unknown	no	1	no	no	unknown	5	may	

```
In [10]:
# KarinaAuliaWulandari - 202431047
data.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 45211 entries, 0 to 45210
Data columns (total 17 columns):
 #   Column     Non-Null Count  Dtype
---  ------     --------------  -----
 0   age        45211 non-null  int64
 1   job        45211 non-null  object
 2   marital    45211 non-null  object
 3   education  45211 non-null  object
 4   default    45211 non-null  object
 5   balance    45211 non-null  int64
 6   housing    45211 non-null  object
 7   loan       45211 non-null  object
 8   contact    45211 non-null  object
 9   day        45211 non-null  int64
 10  month      45211 non-null  object
 11  duration   45211 non-null  int64
 12  campaign   45211 non-null  int64
 13  pdays      45211 non-null  int64
 14  previous   45211 non-null  int64
 15  poutcome   45211 non-null  object
 16  y          45211 non-null  object
dtypes: int64(7), object(10)
memory usage: 5.9+ MB
```

data.head() menampilkan lima baris awal untuk memastikan data terbaca dengan benar, sedangkan data.info() menampilkan jumlah baris, tipe data, dan jumlah nilai non-null tiap kolom. Fitur bertipe angka adalah age, balance, day, duration, campaign, pdays, dan previous (7 fitur numerik), sedangkan job, marital, education, default, housing, loan, contact, month, poutcome, serta y bertipe kategorikal.

3.2 Analisis Data Eksploratif

3.2.1 Ukuran data, nilai hilang, dan duplikasi

Kode mencetak data.shape, data.isnull().sum(), dan data.duplicated().sum(). Kode juga memisahkan fitur numerik dan kategorikal menggunakan pd.api.types.is_numeric_dtype, lalu menampilkan nilai unik tiap fitur kategorikal.

```
In [12]:
# KarinaAuliaWulandari - 202431047
print("ukuran data (baris, kolom) =", data.shape)
print("\nmissing value per kolom:")
print(data.isnull().sum())
print("\njumlah data duplikat =", data.duplicated().sum())
```

```
ukuran data (baris, kolom) = (45211, 17)

missing value per kolom:
age          0
job          0
marital      0
education    0
default      0
balance      0
housing      0
loan         0
contact      0
day          0
month        0
duration     0
campaign     0
pdays        0
previous     0
poutcome     0
y            0
dtype: int64

jumlah data duplikat = 0
```

3.2.2 Statistik deskriptif

```
In [11]:
# KarinaAuliaWulandari - 202431047
data.describe()
```

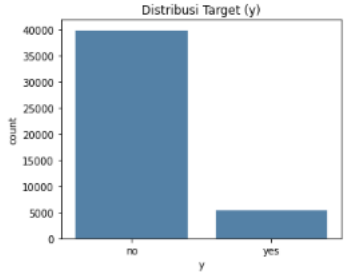
Out[11]:

	age	balance	day	duration	campaign	pdays	previous
count	45211.000000	45211.000000	45211.000000	45211.000000	45211.000000	45211.000000	45211.000000
mean	40.936210	1362.272058	15.806419	258.163080	2.763841	40.197828	0.580323
std	10.618762	3044.765829	8.322476	257.527812	3.098021	100.128746	2.303441
min	18.000000	-8019.000000	1.000000	0.000000	1.000000	-1.000000	0.000000
25%	33.000000	72.000000	8.000000	103.000000	1.000000	-1.000000	0.000000
50%	39.000000	448.000000	16.000000	180.000000	2.000000	-1.000000	0.000000
75%	48.000000	1428.000000	21.000000	319.000000	3.000000	-1.000000	0.000000
max	95.000000	102127.000000	31.000000	4918.000000	63.000000	871.000000	275.000000

3.2.3 Distribusi target (y)

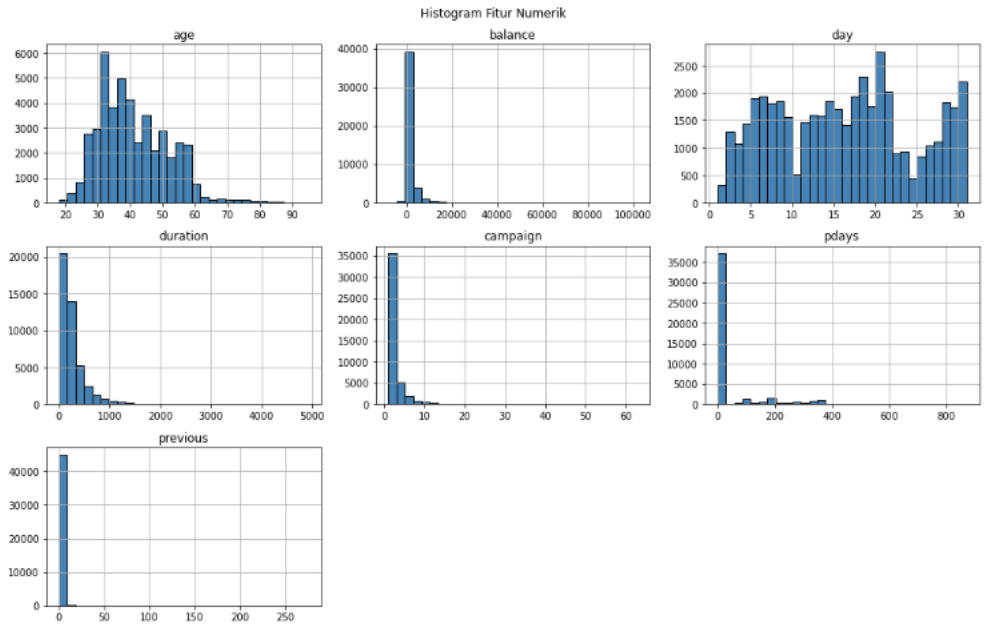
Kode menampilkan value_counts() dan proporsi (dalam persen) kelas no dan yes, serta grafik countplot.

```
no     39922
yes     5289
Name: y, dtype: int64
no     88.3
yes    11.7
Name: y, dtype: float64
```



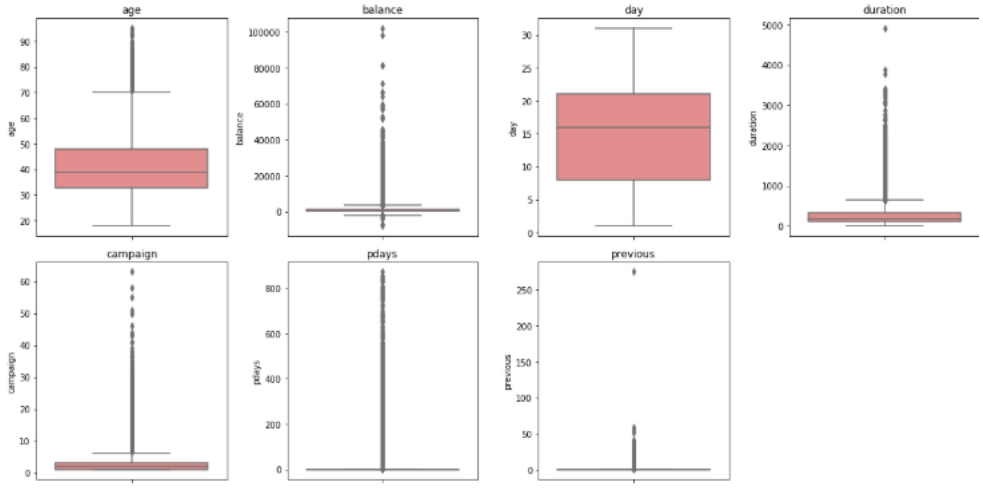
3.2.4 Distribusi fitur numerik

Kode membuat histogram 30 bin untuk setiap fitur numerik dan boxplot dalam grid 2×4 (7 fitur numerik, panel ke-8 dimatikan).



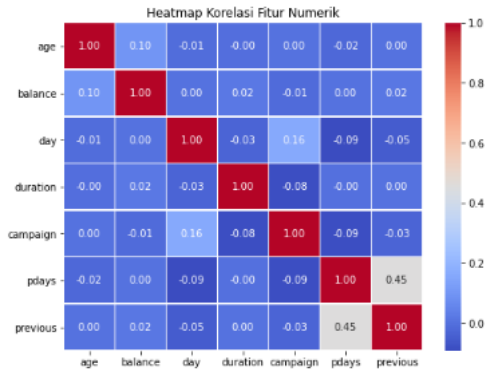
3.2.5 Fitur kategorikal terhadap target

Kode membuat countplot dengan hue y untuk sembilan fitur kategorikal dalam grid 3×3.



3.2.6 Korelasi fitur numerik

Kode menampilkan heatmap korelasi antar tujuh fitur numerik.



3.3 Naive Bayes

3.3.1 Preprocessing (Label Encoding)

Data disalin ke data_nb agar data asli tetap utuh untuk bagian KNN. Setiap fitur kategorikal (termasuk target y) diubah menjadi angka menggunakan LabelEncoder. Setelah encoding, y bernilai 0 untuk no dan 1 untuk yes. Fitur (x) dan target (y) kemudian dipisahkan.

```
In [25]:
# KarinaAuliaWulandari - 202431047
data_nb.head()
```

Out[25]:

	age	job	marital	education	default	balance	housing	loan	contact	day	month	duration	campaign	pdays	previous	poutcome	y
0	58	4	1	2	0	2143	1	0	2	5	8	261	1	-1	0	3	0
1	44	9	2	1	0	29	1	0	2	5	8	151	1	-1	0	3	0
2	33	2	1	1	0	2	1	1	2	5	8	76	1	-1	0	3	0
3	47	1	1	3	0	1506	1	0	2	5	8	92	1	-1	0	3	0
4	33	11	2	3	0	1	0	0	2	5	8	198	1	-1	0	3	0

3.3.2 Pembagian data dan pelatihan

Data dibagi dengan train_test_split dengan test_size=0.25 dan random_state=0 sehingga 75% menjadi data latih dan 25% data uji. Model GaussianNB dilatih dengan model.fit(x_train, y_train).

3. Split Data & Training Naive Bayes

```
In [29]:
# KarinaAuliaWulandari - 202431047
from sklearn.model_selection import train_test_split

x_train, x_test, y_train, y_test = train_test_split(x, y, test_size=0.25, random_state=0)
print(f'x_train shape : {x_train.shape}')
print(f'x_test shape  : {x_test.shape}')
```

```
x_train shape : (33908, 16)
x_test shape  : (11303, 16)
```

3.3.3 Evaluasi

Kode menghitung akurasi pada data latih dan data uji, menampilkan confusion matrix untuk keduanya (heatmap merah untuk data latih dan biru untuk data uji), dan classification report pada data uji.

4. Evaluasi Naive Bayes

In [31]:
```
# KarinaAuliaWulandari - 202431047
from sklearn.metrics import accuracy_score, confusion_matrix, classification_report

y_pred_train = model.predict(x_train)
y_pred_test = model.predict(x_test)

acc_nb_train = accuracy_score(y_train, y_pred_train)
acc_nb_test = accuracy_score(y_test, y_pred_test)

print(f"Akurasi Naive Bayes (data train) : {acc_nb_train:.4f}")
print(f"Akurasi Naive Bayes (data test)  : {acc_nb_test:.4f}")
```

```
Akurasi Naive Bayes (data train) : 0.8458
Akurasi Naive Bayes (data test)  : 0.8415
```

3.3.4 Prediksi nasabah baru

Sebuah nasabah baru dibuat dalam DataFrame dengan nilai age=45, balance=1500, day=15, duration=300, campaign=2, pdays=-1, previous=0, dan fitur kategorikal yang sudah berupa kode LabelEncoder. Model memprediksi kelas nasabah tersebut (0 = no, 1 = yes).

5. Prediksi Data Baru

In [36]:
```
# KarinaAuliaWulandari - 202431047
print(list(x.columns))

# age, job, marital, education, default, balance, housing, loan, contact, day, month, duration, campaign, pdays, previous, p
# (nilai kategori berupa hasil LabelEncoder, bukan teks)
new_customer = pd.DataFrame([[45, 4, 1, 2, 0, 1500, 1, 0, 0, 15, 8, 300, 2, -1, 0, 3]], columns=x.columns)
prediction = model.predict(new_customer)
print("prediksi nasabah baru (0 = no, 1 = yes):", prediction[0])
```

```
['age', 'job', 'marital', 'education', 'default', 'balance', 'housing', 'loan', 'contact', 'day', 'month', 'duration', 'campaig
n', 'pdays', 'previous', 'poutcome']
prediksi nasabah baru (0 = no, 1 = yes): 0
```

3.4 K-Nearest Neighbors

3.4.1 Load data dan preprocessing

Data dimuat ulang, lalu fitur dan target dipisahkan. Target dipetakan no menjadi 0 dan yes menjadi 1. Fitur kategorikal diubah menggunakan pd.get_dummies(drop_first=True), kemudian seluruh kolom dikonversi ke tipe float. Pada KNN dipilih One-Hot Encoding karena KNN menghitung jarak, sehingga urutan semu dari Label Encoding akan merusak perhitungan jarak antar kategori.

In [41]:
```
# KarinaAuliaWulandari - 202431047
y = y.map({'no': 0, 'yes': 1})

x = pd.get_dummies(x, drop_first=True)
x = x.astype(float)

print(x.dtypes.value_counts())
print("jumlah fitur setelah encoding =", x.shape[1])
x.head()
```

```
float64    42
dtype: int64
jumlah fitur setelah encoding = 42
```

Out[41]:

	age	balance	day	duration	campaign	pdays	previous	job_blue-collar	job_entrepreneur	job_housemaid	...	month_jul	month_jun	month_mar	month_may	r
0	58.0	2143.0	5.0	261.0	1.0	-1.0	0.0	0.0	0.0	0.0	...	0.0	0.0	0.0	1.0	
1	44.0	29.0	5.0	151.0	1.0	-1.0	0.0	0.0	0.0	0.0	...	0.0	0.0	0.0	1.0	
2	33.0	2.0	5.0	76.0	1.0	-1.0	0.0	0.0	1.0	0.0	...	0.0	0.0	0.0	1.0	
3	47.0	1506.0	5.0	92.0	1.0	-1.0	0.0	1.0	0.0	0.0	...	0.0	0.0	0.0	1.0	
4	33.0	1.0	5.0	198.0	1.0	-1.0	0.0	0.0	0.0	0.0	...	0.0	0.0	0.0	1.0	

5 rows × 42 columns

3.4.2 Pembagian data

Pembagian data memakai proporsi dan random_state yang sama dengan Naive Bayes (75:25, random_state=0), sehingga perbandingan kedua model adil karena menggunakan data uji yang identik.

2. Split Data

In [42]:
```
# KarinaAuliaWulandari - 202431047
from sklearn.model_selection import train_test_split
x_train, x_test, y_train, y_test = train_test_split(x, y, test_size=0.25, random_state=0)
```

In [43]:
```
# KarinaAuliaWulandari - 202431047
print(f'x_train shape : {x_train.shape}')
print(f'x_test shape : {x_test.shape}')
```

```
x_train shape : (33908, 42)
x_test shape : (11303, 42)
```

3.4.3 KNN tanpa scaling (K = 7)

Model KNeighborsClassifier dengan n_neighbors=7 dilatih langsung pada data tanpa penskalaan.

3. KNN tanpa Scaling (K = 7)

In [44]:
```
# KarinaAuliaWulandari - 202431047
from sklearn.neighbors import KNeighborsClassifier
from sklearn.metrics import accuracy_score, classification_report, confusion_matrix

knn = KNeighborsClassifier(n_neighbors=7)
knn.fit(x_train, y_train)
```

Out[44]:
```
KNeighborsClassifier(n_neighbors=7)
```

In [45]:
```
# KarinaAuliaWulandari - 202431047
y_pred = knn.predict(x_test)
```

In [46]:
```
# KarinaAuliaWulandari - 202431047
acc_knn_raw = accuracy_score(y_test, y_pred)
print(f"Akurasi KNN (K=7, tanpa scaling): {acc_knn_raw:.4f}")
```

```
Akurasi KNN (K=7, tanpa scaling): 0.8817
```

3.4.4 KNN dengan scaling (StandardScaler)

StandardScaler di-fit hanya pada x_train, lalu diterapkan ke x_train dan x_test. Model KNN dengan K=15 dicoba pada data terskala.

4. KNN dengan Scaling (StandardScaler)

In [47]:
```
# KarinaAuliaWulandari - 202431047
from sklearn.preprocessing import StandardScaler
scaler = StandardScaler()
scaler.fit(x_train)

# Transform x_train dan x_test
x_train_scaled = scaler.transform(x_train)
x_test_scaled = scaler.transform(x_test)
```

In [48]:
```
# KarinaAuliaWulandari - 202431047
K_TARGET = 15
model_k15 = KNeighborsClassifier(n_neighbors=K_TARGET)
model_k15.fit(x_train_scaled, y_train)
y_pred_k15 = model_k15.predict(x_test_scaled)

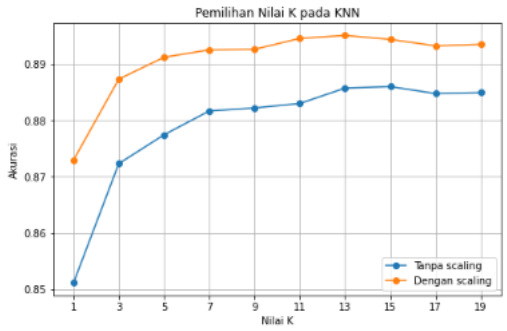
# Hitung Akurasi Model
accuracy_k15 = accuracy_score(y_test, y_pred_k15)

print(f"Nilai K yang digunakan: {K_TARGET}")
print(f"Akurasi Model KNN pada data test: {accuracy_k15:.4f}")
```

```
Nilai K yang digunakan: 15
Akurasi Model KNN pada data test: 0.8945
```

3.4.5 Pemilihan nilai K terbaik

Kode melakukan perulangan untuk K ganjil dari 1 hingga 19, melatih KNN pada data tanpa scaling dan dengan scaling, lalu memplot akurasi uji terhadap K. K terbaik dipilih dari akurasi tertinggi pada data terskala (np.argmax).

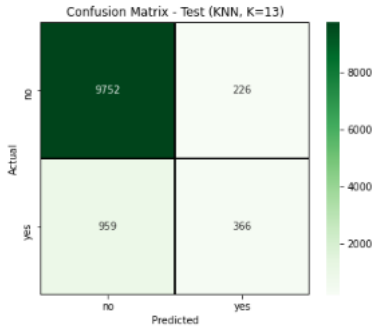



```
K terbaik (data scaling) = 13 dengan akurasi 0.8952
```

3.4.6 Evaluasi KNN terbaik

Model KNN dengan K terbaik dilatih ulang pada data terskala, lalu dievaluasi dengan akurasi, confusion matrix (heatmap hijau), dan classification report.

```
Akurasi KNN terbaik (K=13) : 0.8952
```



	precision	recall	f1-score	support
no	0.91	0.98	0.94	9978
yes	0.62	0.28	0.38	1325
accuracy			0.90	11303
macro avg	0.76	0.63	0.66	11303
weighted avg	0.88	0.90	0.88	11303

3.4.7 Prediksi data baru (KNN)

Baris pertama data uji dipilih sebagai contoh, diskalakan dengan scaler yang sama, lalu diprediksi dan dibandingkan dengan label aslinya.

7. Prediksi Data Baru (KNN)

In [55]:
```
# KarinaAuliaWulandari - 202431047
x_new = x_test.iloc[[0]]
x_new_scaled = scaler.transform(x_new)

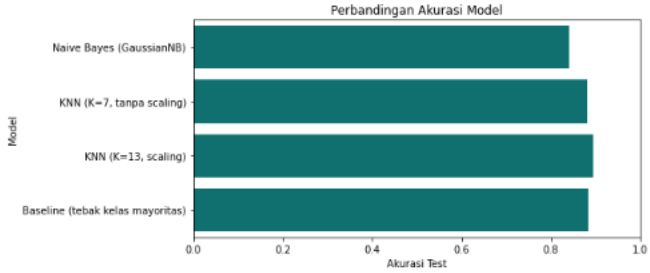
print("prediksi KNN  :", knn_best.predict(x_new_scaled)[0], "(0 = no, 1 = yes)")
print("label aslinya :", y_test.iloc[0])
```

```
prediksi KNN  : 0 (0 = no, 1 = yes)
label aslinya : 0
```

3.5 Perbandingan Naive Bayes dan KNN

Kode menyusun tabel perbandingan akurasi uji untuk empat pembanding: Naive Bayes, KNN (K=7 tanpa scaling), KNN dengan K terbaik dan scaling, serta baseline kelas mayoritas (akurasi bila selalu menebak kelas terbanyak), kemudian menampilkannya dalam bar chart.

	Model	Akurasi Test
0	Naive Bayes (GaussianNB)	0.841546
1	KNN (K=7, tanpa scaling)	0.881713
2	KNN (K=13, scaling)	0.895161
3	Baseline (tebak kelas mayoritas)	0.882774



BAB IV
PENUTUP

Berdasarkan landasan teori dan hasil praktikum, dapat disimpulkan bahwa:

1. EDA menunjukkan data nasabah bank terdiri dari 7 fitur numerik dan 9 fitur kategorikal dengan target biner y. Pemeriksaan distribusi target diperlukan karena data pemasaran bank pada umumnya tidak seimbang, sehingga akurasi harus dibaca bersama baseline kelas mayoritas (Hayder dkk., 2023). [ISI: ringkas temuan EDA Anda: proporsi yes/no, nilai hilang, duplikasi, pencilan.]

2. Pra-pemrosesan disesuaikan dengan algoritma: Label Encoding untuk Naive Bayes dan One-Hot Encoding plus StandardScaler untuk KNN. Pilihan ini penting karena KNN berbasis jarak dan sensitif pada skala fitur (Niño-Adan dkk., 2022; Peshawa, 2022), sedangkan GaussianNB mengandalkan asumsi distribusi normal dan independensi fitur (Wickramasinghe & Kalutarage, 2021; Liu dkk., 2024).

3. Model Naive Bayes mencapai akurasi uji [ISI] dan KNN terbaik (K = [ISI], dengan scaling) mencapai akurasi uji [ISI], dibandingkan baseline [ISI]. [ISI: nyatakan model terbaik berdasarkan akurasi, recall, dan F1 kelas yes, serta apakah scaling meningkatkan akurasi KNN.]

4. Keterbatasan praktikum ini adalah pemilihan K berdasarkan data uji, pembagian data tanpa stratifikasi, penggunaan Label Encoding pada fitur nominal untuk GaussianNB, dan belum adanya penanganan ketidakseimbangan kelas. Saran pengembangan: gunakan validasi silang, stratified split, teknik penanganan imbalance seperti SMOTE, penyetelan hyperparameter, serta metrik recall dan F1 sebagai pertimbangan utama.

DAFTAR PUSTAKA

Hayder, I. M., Al Ali, G. A. N., & Younis, H. A. (2023). Predicting reaction based on customer's transaction using machine learning approaches. International Journal of Electrical and Computer Engineering (IJECE), 13(1), 1086–1096. https://doi.org/10.11591/ijece.v13i1.pp1086-1096

Liu, H., Wang, S., & Jiang, L. (2024). Alleviating conditional independence assumption of naive Bayes. Statistical Papers, 65, 2767–2797.

Niño-Adan, I., Landa-Torres, I., Portillo, E., & Manjarres, D. (2022). Influence of statistical feature normalisation methods on K-Nearest Neighbours and K-Means in the context of industry 4.0. Engineering Applications of Artificial Intelligence, 111, 104807. https://doi.org/10.1016/j.engappai.2022.104807

Peshawa, J. M. A. (2022). Investigating the impact of min-max data normalization on the regression performance of K-nearest neighbor with different similarity measurements. ARO – The Scientific Journal of Koya University, 10(1). https://doi.org/10.14500/aro.10955

Wickramasinghe, I., & Kalutarage, H. (2021). Naive Bayes: Applications, variations and vulnerabilities: A review of literature with code snippets for implementation. Soft Computing, 25, 2277–2293.